中图分类号：TP312
论 文 编 号：10006SY0000000

北京航空航天大學

硕 士 学 位 论 文

多维度可靠性感知的自适应融合：面向 UAV 导航的多模态传感器融合框架

基于可靠性估计、动态权重与自适应归一化的端到端强化学习集成

作 者 姓 名　姓名
学 科 专 业　XXXX
指 导 教 师　导师中文名　教授
培 养 院 系　XXX 学院

Multi-dimensional Reliability-Aware Adaptive Fusion for UAV Navigation

End-to-end RL integration with reliability estimation, dynamic weighting and adaptive normalization

A Dissertation Submitted for the Degree of Master

Candidate: Name

Supervisor: Prof. Name of tutor

School of XXX

Beihang University, Beijing, China

中图分类号：**TP312**
论 文 编 号：**10006SY0000000**

硕　士　学　位　论　文

多维度可靠性感知的自适应融合：面向 UAV 导航的多模态传感器融合框架

作者姓名	姓名	申请学位级别	全日制工程硕士
指导教师姓名	导师中文名	职　　称	教授
学科专业	XXXX	研究方向	大数据和云计算
学习时间自	2011 年 09 月 01 日	起至	2012 年 07 月 01 日止
论文提交日期	2012 年 03 月 03 日	论文答辩日期	2012 年 06 月 01 日
学位授予单位	北京航空航天大学	学位授予日期	2012 年 04 月 04 日

关于学位论文的独创性声明

本人郑重声明：所呈交的论文是本人在指导教师指导下独立进行研究工作所取得的成果，论文中有关资料和数据是实事求是的。尽我所知，除文中已经加以标注和致谢外，本论文不包含其他人已经发表或撰写的研究成果，也不包含本人或他人为获得北京航空航天大学或其它教育机构的学位或学历证书而使用过的材料。与我一同工作的同志对研究所做的任何贡献均已在论文中作出了明确的说明。

若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名：_____　　日期：　　年　　月　　日

学位论文使用授权书

本人完全同意北京航空航天大学有权使用本学位论文（包括但不限于其印刷版和电子版），使用方式包括但不限于：保留学位论文，按规定向国家有关部门（机构）送交学位论文，以学术交流为目的赠送和交换学位论文，允许学位论文被查阅、借阅和复印，将学位论文的全部或部分内容编入有关数据库进行检索，采用影印、缩印或其他复制手段保存学位论文。

保密学位论文在解密后的使用授权同上。

学位论文作者签名：_____　　日期：　　年　　月　　日

指导教师签名：_____　　日期：　　年　　月　　日

摘　要

本文面向复杂环境下无人机（UAV）自主导航任务，研究多模态传感器（LiDAR、RGB、IMU）在质量退化与噪声扰动场景中的鲁棒融合问题。针对传统固定权重或直接拼接式融合难以适应模态可靠性动态变化的不足，本文提出一种多维度可靠性感知的自适应融合框架（Idea1）：首先从点云信噪比、图像清晰度/对比度等质量指标以及 IMU 时序一致性等角度对各模态进行显式可靠性估计；其次利用可靠性预测网络聚合模态质量特征，并通过基于注意力机制的动态权重分配与自适应归一化实现特征级融合；最后将融合模块封装为 Stable-Baselines3 兼容的特征提取器，支持 SAC 等强化学习算法端到端训练。

目前，本项目已完成核心网络、退化注入仿真环境、难度分级评测设置与自动化实验脚本的实现，并通过集成测试验证了 SB3 流水线可运行。在本地 CPU 上，1000 时间步训练已可稳定完成（约 32 秒）。初步实验表明：在中等难度场景（degradation=0.5）下，可靠性感知融合模型相较无可靠性基线获得更高平均回报；在困难场景下，无可靠性基线碰撞率显著上升（30%），显示可靠性感知机制对鲁棒性具有积极作用。受算力与周期限制，跨多随机种子的大规模长时训练（10k~100k 步）仍在持续迭代中。

关键词：无人机导航，多模态融合，可靠性估计，动态权重，强化学习

Abstract

This thesis studies robust multi-modal sensor fusion for UAV navigation under sensor quality degradation and noise, with three modalities (LiDAR, RGB, and IMU). We propose Idea1, a reliability-aware adaptive fusion framework: (1) explicitly estimate modality reliability from LiDAR SNR, image quality metrics, and IMU temporal consistency; (2) aggregate quality features with a lightweight reliability predictor, then perform attention-based dynamic weighting and reliability-guided adaptive normalization for feature fusion; (3) integrate the fusion module into a Stable-Baselines3 compatible feature extractor to enable end-to-end reinforcement learning (e.g., SAC).

The repository now includes the full core pipeline, degradation injection, difficulty presets, and reproducible experiment scripts, and it passes integration tests. On local CPU, 1000-step training is stable ($\sim$ 32 seconds). Preliminary results show that reliability-aware fusion improves average return over the no-reliability baseline in moderate degradation settings, while in hard settings the no-reliability baseline shows a much higher collision rate (30%). Large-scale multi-seed long-horizon training (10k–100k steps) remains ongoing due compute limits.

Key words: UAV navigation, multimodal fusion, reliability estimation, dynamic weighting, reinforcement learning

目　　录

第一章 绪论 …… 1

1.1 研究背景与意义 …… 1

1.2 问题定义与研究内容 …… 1

1.2.1 问题定义 …… 1

1.2.2 研究内容 …… 1

1.3 主要工作与创新点 …… 2

1.4 技术路线（示意） …… 2

1.5 论文结构 …… 2

第二章 相关工作与技术背景 …… 3

2.1 多模态融合与可靠性建模 …… 3

2.1.1 注意力机制与权重归一化 …… 3

2.1.2 不确定性与质量度量 …… 4

2.2 强化学习在无人机导航中的应用 …… 4

2.3 本文方法定位 …… 4

第三章 系统总体设计与方法概述 …… 5

3.1 系统输入与输出 …… 5

3.2 仿真环境与交互接口 …… 5

3.2.1 观测空间 …… 5

3.2.2 动作空间 …… 5

3.2.3 奖励函数（与代码一致的形式化表达） …… 6

3.3 可靠性感知融合流程 …… 6

3.4 符号与约定 …… 6

3.5 与强化学习训练的集成 …… 7

第四章 核心方法、关键算法与理论推导 …… 9

4.1 范围声明与实现边界 …… 9

4.2 问题形式化与目标 …… 9

4.3 可靠性估计器设计与理论推导 …… 9

4.3.1 LiDAR 信噪比估计（密度-均匀性融合） …… 9

4.3.2 RGB 图像质量评估（多维质量指标） …… 10

4.3.3 IMU 一致性检查（漂移与异常） …… 11
4.4 可靠性预测网络（共享表征） …… 11
4.5 动态权重分配的理论推导 …… 11
4.5.1 温度缩放的极限分析 …… 12
4.6 特征归一化与可靠性调制 …… 12
4.7 端到端融合与损失函数 …… 13
4.8 与强化学习的联合优化（SAC） …… 13
4.9 理论分析补充：鲁棒性与信息论（基于假设的推导） …… 13
4.9.1 最坏情况鲁棒性直观分析 …… 14
4.9.2 互信息视角的融合动机 …… 14
4.10 与 SB3 特征提取器的接口约束 …… 14
第五章 实验设计与评估 …… 15
5.1 实验目标 …… 15
5.2 实验设置 …… 15
5.2.1 算法与实现 …… 15
5.2.2 环境与退化注入 …… 15
5.2.3 可复现实验脚本 …… 15
5.3 评价指标 …… 16
5.4 对比方法 …… 16
5.5 结果与分析（当前可复现结果） …… 16
5.5.1 中等难度结果（single seed，degradation=0.5） …… 16
5.5.2 困难难度结果（single seed，degradation=0.5） …… 16
5.5.3 困难难度三随机种子汇总（timesteps=1000） …… 17
5.5.4 结果讨论 …… 17
5.6 当前局限与后续迭代 …… 18
第六章 工程实现与复现说明 …… 19
6.1 代码结构 …… 19
6.2 关键接口与张量形状 …… 19
6.3 模型规模与开销 …… 19
6.4 训练性能优化实现 …… 20
6.5 运行方式 …… 20
6.5.1 训练入口 …… 20

6.5.2 实验套件 …… 20
6.6 测试与复现状态 …… 20
6.7 未完成事项 …… 21
总结 …… 23
参考文献 …… 25
附录 A 常见问题 …… 27
附录 B 联系我们 …… 29
致谢 …… 31
作者简介 …… 33

插 图 目 录

表 格 目 录

表 1　中等难度结果（degradation=0.5，seed=42） …… 17

表 2　困难难度结果（degradation=0.5，seed=42） …… 17

表 3　困难难度三随机种子汇总（degradation=0.5） …… 17

主要符号对照表

HPC	高性能计算 (High Performance Computing)
cluster	集群
Itanium	安腾
SMP	对称多处理
API	应用程序编程接口
PI	聚酰亚胺
MPI	聚酰亚胺模型化合物，N-苯基邻苯酰亚胺
PBI	聚苯并咪唑
MPBI	聚苯并咪唑模型化合物，N-苯基苯并咪唑
PY	聚吡咙
PMDA-BDA	均苯四酸二酐与联苯四胺合成的聚吡咙薄膜
ΔG	活化自由能 (Activation Free Energy)
χ	传输系数 (Transmission Coefficient)
E	能量
m	质量
c	光速
P	概率
T	时间
v	速度

第一章　绪论

1.1　研究背景与意义

无人机自主导航通常需要在复杂、动态且部分可观测的环境中完成避障与目标到达任务。在遮挡、光照变化、电磁干扰或传感器老化等条件下，单一传感器容易发生感知退化，导致感知不稳定并进一步影响下游决策。多模态融合（LiDAR、RGB、IMU）能够提供互补信息，但若融合策略无法感知各模态质量变化，则可能在关键时刻放大噪声模态的影响，从而降低系统鲁棒性。

近年来，强化学习（Reinforcement Learning, RL）在端到端控制中表现出较强的策略学习能力，尤其适用于连续动作控制与复杂决策任务。然而，强化学习方法对观测分布漂移和输入噪声较为敏感：当传感器质量发生变化时，策略可能产生性能骤降，甚至引发灾难性碰撞。为此，本文研究一种可解释、可适配的可靠性感知融合机制，并将其与强化学习训练流程紧密集成，旨在提升复杂场景下导航策略的鲁棒性与可用性。

1.2　问题定义与研究内容

1.2.1　问题定义

本文关注的核心问题是：在三模态观测输入（LiDAR 点云、RGB 图像、IMU 惯性数据）存在噪声、缺失或质量波动的条件下，如何设计一种轻量化的可靠性估计与特征融合机制，使融合特征在时变扰动下保持稳定，并能与强化学习算法（SAC）实现端到端协同训练。

1.2.2　研究内容

围绕上述问题，本文的研究内容可归纳为以下四个方面：

1、 构建面向三模态输入的质量度量与可靠性估计机制，并给出形式化定义与性质分析；
2、 设计可端到端训练的特征级融合模块，包括可靠性预测、动态权重分配与特征归一化；
3、 将融合模块封装为 Stable-Baselines3 兼容特征提取器，完成与 SAC 训练流程的工程集成与验证；
4、 设计实验指标与实验协议，给出消融实验与对比实验计划，并对当前可复现结果

进行如实记录。

1.3　主要工作与创新点

本项目（Idea1）在代码仓库中完成实现，核心工作包括：

1、 显式可靠性估计：针对每种模态构建质量度量模块，输出可解释的可靠性相关特征与评分。
2、 可靠性感知自适应融合：结合可靠性预测网络、基于注意力的动态权重分配以及特征归一化，实现端到端特征级融合。
3、 强化学习端到端集成：将融合模块封装为 Stable-Baselines3 兼容特征提取器，支持多模态观测字典输入与 SAC 训练。

1.4　技术路线（示意）

本文的技术路线可概括为" 多模态观测 → 可靠性估计 → 动态加权融合 → RL 策略学习"。

TODO/待补充：可在后续补充技术路线图（例如系统流程图或模块依赖图），并将仓库中的模块关系（见 networks/与 envs/）可视化。

1.5　论文结构

本文其余章节组织如下：第 2 章介绍相关工作与技术背景；第 3 章给出系统总体设计与方法概述；第 4 章详细阐述核心模块、关键算法与理论推导；第 5 章给出实验设计、评价指标与当前可复现实验状态（含 TODO 占位）；第 6 章说明工程实现与复现方式；第 7 章总结全文并展望后续工作。

第二章　相关工作与技术背景

2.1　多模态融合与可靠性建模

多模态学习（Multimodal Learning）研究如何在统一模型中利用多源异构信息提升感知与决策能力。综述工作 [1] 将多模态问题抽象为表示、对齐、融合与协同四类核心挑战。针对融合阶段，工程上常见策略包括：特征拼接、固定权重加权、门控网络（gating）以及注意力机制等。固定权重方法实现简单，但对模态质量的动态变化不敏感；注意力与门控机制能够在一定程度上自适应分配模态贡献，但若缺少显式质量或不确定性约束，则可能学习到难以解释且对分布漂移不稳健的权重。

近年来，关于”低质量输入/模态缺失”下的多模态融合开始成为重要研究方向，相关综述 [2] 系统讨论了噪声、缺失、遮挡与质量波动等问题设置与应对方法，为本文的”退化注入实验”提供了定义与对比框架。

可靠性建模方面，已有方法常使用不确定性估计（如 Monte Carlo Dropout 与贝叶斯近似）或基于任务损失的隐式学习。Gal 与 Ghahramani[3] 指出 dropout 可被解释为近似贝叶斯推断，从而在不改变网络结构的情况下估计模型不确定性；Kendall 与 Gal[4] 进一步区分了观测噪声（aleatoric uncertainty）与模型不确定性（epistemic uncertainty），为基于不确定性的可靠性建模提供了经典框架。相比之下，本文更偏向从物理与信号层面构建显式质量指标，例如点云密度/均匀性与信噪比、图像锐度/对比度以及 IMU 一致性，从而为融合提供可解释的”质量先验”。

2.1.1　注意力机制与权重归一化

注意力机制通过可学习的相关性打分实现信息选择与加权聚合，多头注意力 [5] 能够并行建模不同的子空间关系，在多模态融合中常用于跨模态对齐或模态间交互。本文在融合模块中使用注意力得到模态权重，并通过 softmax 确保权重和为 1，从而满足融合约束。

在自动驾驶等领域，LiDAR-相机融合的代表工作 BEVFusion[6] 在统一 BEV 空间完成多传感器融合，体现了”结构化空间表征 + 融合”的一类主流范式。本文与此不同：本文聚焦轻量级可靠性估计与权重分配，将其集成为强化学习的特征提取器，以验证”可靠性感知融合”在决策闭环中的收益。

2.1.2　不确定性与质量度量

不确定性建模是可靠性估计的常见途径之一，例如通过贝叶斯近似或 Monte Carlo Dropout 估计预测分布的方差，并将其作为权重或门控信号。本文更偏向使用可解释的质量度量作为可靠性输入：该选择的优点是计算开销小、易调试、易进行故障分析；不足之处是质量度量与任务相关性的映射可能需要通过学习进一步校准。

针对传感器失效场景，近期也出现了面向缺失/噪声模态的鲁棒性评测与方法设计，例如缺失与噪声模态下的多模态基准 [7] 以及面向失效的专家混合融合策略 [8]。这些工作为本文”NM/EMM/RMM” 等退化场景的设定提供了可参考的实验范式。

2.2　强化学习在无人机导航中的应用

强化学习可以直接从交互数据中学习从观测到动作的映射，尤其在高维、多模态输入场景中具有优势。本文实现采用 SAC 算法，并基于 Stable-Baselines3 的 MultiInputPolicy 处理字典型观测输入。为保证可复现性与工程可用性，本文将融合模块集成为 SB3 特征提取器，使训练、日志与评估流程与主流 RL 工具链一致。

本文实现所依赖的关键工具链包括：SAC 算法 [9]、Stable-Baselines3[10]、Gymnasium 环境接口 [11] 以及 PyTorch 深度学习框架 [12]。

2.3　本文方法定位

本文方法的关键定位为：显式可靠性估计 + 自适应融合 **+RL** 端到端集成。与仅在融合层学习权重的做法不同，本文在权重分配之前引入可解释质量信号，并在融合过程中通过自适应归一化抑制不可靠模态带来的尺度扰动，从而提升鲁棒性。

第三章　系统总体设计与方法概述

3.1　系统输入与输出

系统以三模态观测作为输入：

- **LiDAR**：点云 $\in \mathbb{R}^{N\times 3}$（默认 $N = 1000$）。
- **RGB**：图像 $\in \mathbb{R}^{H\times W\times 3}$（默认 $H = W = 128$）。
- **IMU**：惯性数据 $\in \mathbb{R}^{6}$（加速度计与陀螺仪）。

系统输出为用于 RL 策略网络的融合特征向量（默认 256 维），并可选返回中间信息（可靠性分数、权重分配、归一化后的模态特征），用于可视化与调试。

3.2　仿真环境与交互接口

本文实现使用 Gymnasium 接口构建 UAV 多模态仿真环境，其交互形式为标准的 Markov 决策过程（MDP）：在时刻 t，环境返回观测 o_t，策略输出动作 a_t，环境产生奖励 r_t 并转移到下一个状态。

3.2.1　观测空间

环境观测为字典形式：

$$o_t = \{o_t^L, o_t^R, o_t^I\} \tag{3.1}$$

其中：o_t^L 为点云，o_t^R 为图像，o_t^I 为 IMU 数据。该设计能够直接对接 Stable-Baselines3 的 MultiInputPolicy。

3.2.2　动作空间

动作空间为四维连续向量：

$$a_t = [v_x, v_y, v_z, \omega]^\top, \quad a_t \in [-1, 1]^4 \tag{3.2}$$

分别对应线速度与角速度控制分量。

3.2.3　奖励函数（与代码一致的形式化表达）

根据环境实现，奖励主要由到目标距离、碰撞惩罚、速度惩罚和到达目标奖励构成。设无人机位置为 p_t，目标位置为 p_g，则距离项为：

$$r_{\text{dist}}(t) = -\|p_t - p_g\|_2 \tag{3.3}$$

速度惩罚项为：

$$r_{\text{speed}}(t) = -0.01\,\|v_t\|_2 \tag{3.4}$$

若发生碰撞则施加固定惩罚 $r_{\text{coll}} = -100$；若到达目标半径内则施加奖励 $r_{\text{goal}} = 100$。因此总体奖励：

$$r_t = r_{\text{dist}}(t) + r_{\text{speed}}(t) + r_{\text{coll}}(t) + r_{\text{goal}}(t) \tag{3.5}$$

说明：上述形式与当前仓库环境代码一致，但该环境仍为简化仿真版本，未引入真实传感器噪声模型与复杂动力学。

3.3　可靠性感知融合流程

Idea1 的融合流程可概括为以下步骤：

1、 模态质量估计：为每个模态提取质量特征并输出质量相关分数。

2、 可靠性预测：融合质量特征得到各模态可靠性分数 $r_{lidar}, r_{rgb}, r_{imu} \in [0, 1]$ 以及共享特征表征 $\mathbf{f}$。

3、 动态权重分配：对 $\mathbf{f}$ 进行模态分支映射，利用多头注意力生成模态权重 $w_{lidar}, w_{rgb}, w_{imu}$，并约束 $\sum w = 1$。

4、 自适应归一化与融合：对各模态特征进行归一化与加权，拼接后送入轻量 MLP 输出融合表示。

3.4　符号与约定

为便于后续理论推导，本文采用如下符号约定：

- 模态集合 $\mathcal{M} = \{L, R, I\}$ 分别表示 LiDAR、RGB 与 IMU；
- $r_t^m \in [0, 1]$ 表示模态 m 在时刻 t 的可靠性分数；
- $w_t^m \geq 0$ 表示融合权重，且 $\sum_{m \in \mathcal{M}} w_t^m = 1$；
- $f_t^m \in \mathbb{R}^d$ 表示模态 m 的特征表示（默认 $d = 256$）。

3.5 与强化学习训练的集成

本文在工程上将融合模块封装为 Stable-Baselines3 的特征提取器（BaseFeaturesExtractor），使其可直接用于 SAC 的 MultiInputPolicy。训练入口脚本提供可靠性模式与基线模式（禁用可靠性、直接拼接）切换，并支持 TensorBoard 日志记录。

第四章　核心方法、关键算法与理论推导

4.1　范围声明与实现边界

本章同时包含工程实现可复现的算法描述与用于解释设计动机的理论推导。为避免过度宣称，本文明确区分如下两类内容：

- 实现事实（**Implemented**）：可靠性估计器、可靠性预测网络、注意力权重分配（含温度与偏置）、可靠性调制归一化与融合模块均已在仓库代码中实现，并被集成为 Stable-Baselines3 特征提取器。
- 理论动机（**Sketch under assumptions**）：关于收敛性（如李雅普诺夫意义）与最坏情况鲁棒性（如 H_∞ 相关表述）属于在强假设下的推导草图，用于解释" 为何可靠性感知加权可能更稳健"，并不构成对当前实现与训练流程的严格保证。

4.2　问题形式化与目标

给定多模态观测 $o_t = \{o_t^L, o_t^R, o_t^I\}$，本文希望学习融合映射

$$f_{\text{fusion}} : \mathcal{O}^L \times \mathcal{O}^R \times \mathcal{O}^I \to \mathbb{R}^d \tag{4.1}$$

使得在模态退化场景（噪声、缺失、失效）下，融合特征对扰动不敏感，并能支持强化学习策略稳定收敛。

4.3　可靠性估计器设计与理论推导

本文为三种模态分别设计可靠性估计器，目标是输出可解释的质量度量与可学习的特征表征，供后续可靠性预测与融合使用。

4.3.1　LiDAR 信噪比估计（密度-均匀性融合）

设点云 $P = \{p_i\}_{i=1}^N$，其中 $p_i \in \mathbb{R}^3$。定义点云密度为

$$\rho(P) = \frac{N}{N_{\max}} \in [0, 1] \tag{4.2}$$

其中 $N_{\max}$ 为最大点数（实现中默认 1000）。定义点云中心

$$\mu_P = \frac{1}{N}\sum_{i=1}^{N} p_i \tag{4.3}$$

并令 $d_i = \|p_i - \mu_P\|_2$，其标准差为 σ_d。用指数函数构造均匀性度量

$$\mathcal{U}(P) = \exp\left(-\frac{\sigma_d}{\lambda_U}\right) \tag{4.4}$$

其中 $\lambda_U > 0$ 为尺度参数。最终给出综合 SNR 度量

$$\mathrm{SNR}(P) = \alpha\,\rho(P) + (1-\alpha)\,\mathcal{U}(P) \tag{4.5}$$

性质 **1**（有界性）: 由于 $\rho(P) \in [0,1]$ 且 $\mathcal{U}(P) \in (0,1]$, 当 $\alpha \in [0,1]$ 时有 $\mathrm{SNR}(P) \in [0,1]$。

性质 **2**（单调性）: $\rho(P)$ 关于点数 N 单调递增，$\mathcal{U}(P)$ 关于 σ_d 单调递减；因此该 SNR 度量能够反映” 点云更密集且更均匀 $\Rightarrow$ 质量更高” 的直观规律。

实际实现说明：上述传统度量公式在代码中实现为 compute_traditional_metrics() 辅助方法，主要用于质量评估的理论参考与验证。实际的前向传播采用轻量级卷积神经网络（Conv1d+MLP）对点云进行特征提取，并通过独立的预测头输出信噪比、密度与均匀性分数。该数据驱动方法能够在端到端训练中自动学习与下游任务相关的质量判别准则，同时保留传统度量的可解释性。

4.3.2　RGB 图像质量评估（多维质量指标）

对 RGB 图像 $I \in \mathbb{R}^{H\times W\times 3}$，首先进行灰度转换

$$I_{\text{gray}} = 0.299 I_R + 0.587 I_G + 0.114 I_B \tag{4.6}$$

并采用 Laplacian 算子 ∇^2 计算锐利度指标

$$\mathcal{S}(I) = \mathrm{Var}(\nabla^2 I_{\text{gray}}) \tag{4.7}$$

对比度可由局部窗口标准差统计得到（实现中为 7×7 窗口平均）。亮度质量以平均亮度与理想亮度的偏差度量，纹理复杂度可由梯度方差统计得到。最终将四个维度的质量指标作为输入，经轻量 MLP 得到整体质量评分 $\mathcal{Q}(I) \in [0,1]$。

4.3.3 IMU 一致性检查（漂移与异常）

对 IMU 序列 $X = \{x_t\}_{t=1}^{T}$，其中 $x_t \in \mathbb{R}^6$（加速度计与陀螺仪），通过时序建模与异常检测输出漂移分数与异常分数，并构造一致性分数

$$C_{\text{IMU}}(X) = 1 - 0.5\, D_{\text{drift}}(X) - 0.5\, D_{\text{anom}}(X) \tag{4.8}$$

其中 $D_{\text{drift}}, D_{\text{anom}} \in [0, 1]$。因此 $C_{\text{IMU}}(X) \in [0, 1]$，并具有" 漂移/异常越严重一致性越低" 的语义。

实际实现说明：与传统 LiDAR 估计器类似，上述一致性计算公式在代码中作为 compute_traditional_metrics() 辅助方法提供。当前工程实现采用共享时序 CNN 编码器（Conv1d+Pooling）与轻量预测头联合输出漂移分数、异常分数及 IMU 特征，移除了早期版本中的 LSTM 分支以降低训练开销并提升吞吐率。该实现仍保留一致性分数的可解释语义。

4.4 可靠性预测网络（共享表征）

可靠性预测网络输入为三模态估计器输出的特征与质量指标，输出为

$$\{r_L, r_R, r_I, \mathbf{f}\} = \text{Predictor}(o^L, o^R, o^I) \tag{4.9}$$

其中 $r_m \in [0, 1]$ 表示模态 m 的可靠性分数，$\mathbf{f} \in \mathbb{R}^d$ 为共享融合特征表征（实现中默认 $d = 256$）。共享表征的作用是减少重复编码，并为后续动态权重分配提供统一的特征空间。

4.5 动态权重分配的理论推导

为实现对模态贡献的自适应调整，本文采用注意力机制（Attention）[5] 对模态特征进行交互，并通过 softmax 输出融合权重。设三个模态特征为 $\{f^L, f^R, f^I\}$，堆叠为

$$F = \text{stack}(f^L, f^R, f^I) \in \mathbb{R}^{3\times d} \tag{4.10}$$

实现中使用自注意力（$Q = K = V = F$）得到注意力矩阵 $A \in \mathbb{R}^{3\times 3}$。将第 i 个模态作为 query 时，其对所有 key 的注意力权重为 A_{ij}。为了得到每个模态的单一得分，本文在工

程实现中对其一行做平均得到

$$s_i = \frac{1}{3}\sum_{j=1}^{3} A_{ij}, \quad i \in \{L, R, I\} \tag{4.11}$$

随后对得分做温度缩放并叠加可学习偏置项，最终计算融合权重

$$\mathbf{w} = \mathrm{softmax}\left(\frac{\mathbf{s}}{\tau} + \mathbf{b}\right), \quad \mathbf{w} = [w_L, w_R, w_I]^\top \tag{4.12}$$

其中 $\mathbf{b} = [b_L, b_R, b_I]^\top$ 为偏置。实现中温度参数采用可学习标量并经 sigmoid 约束到 $(0, 1)$：

$$\tau = \sigma(\theta) \in (0, 1) \tag{4.13}$$

由 softmax 性质可得

$$\sum_{m \in \{L,R,I\}} w_m = 1, \quad w_m \geq 0 \tag{4.14}$$

4.5.1　温度缩放的极限分析

当 $\tau \to 0$ 时，softmax 趋向于 one-hot 选择，即权重会集中到打分最大的模态；当 τ 增大时，权重分布更平滑并趋向均匀分配。由于实现中采用 $\tau = \sigma(\theta)$ 将温度限制在 $(0, 1)$，因此其作用更偏向”控制选择的激进程度”（越小越尖锐）。

温度对权重的影响可由梯度直观刻画。令 $\bar{s} = \sum_k w_k s_k$，则有

$$\frac{\partial w_i}{\partial \tau} = \frac{w_i}{\tau^2}(\bar{s} - s_i) \tag{4.15}$$

当某模态得分 s_i 显著高于平均得分 $\bar{s}$ 时，减小 τ 将进一步提高其权重，体现出”可靠模态占优”的自增强效果。

4.6　特征归一化与可靠性调制

不同模态特征在尺度与分布上可能差异较大，且在质量退化时可能引入异常幅值。当前仓库实现的归一化层采用逐模态 L2 归一化并引入可学习缩放/偏置：

$$\hat{f}^m = \frac{f^m - \beta_m}{\|f^m - \beta_m\|_2 + \epsilon}, \quad \tilde{f}^m = \gamma_m \hat{f}^m \tag{4.16}$$

其中 γ_m, β_m 为可学习参数。

实现说明：当前代码已实现可靠性调制版本，其核心形式为

$$\gamma_m^{\text{eff}} = \gamma_m \cdot (1 + \lambda_m r_m), \quad \tilde{f}^m = \gamma_m^{\text{eff}} \hat{f}^m \tag{4.17}$$

其中 λ_m 为可学习参数，$r_m \in [0, 1]$ 为模态可靠性分数。工程实现同时保留 use_reliability_modulation=False 的开关作为消融分支，以便直接比较“有/无可靠性调制归一化”的性能差异。

4.7 端到端融合与损失函数

融合模块在特征级完成加权与拼接：

$$z = \text{concat}(w_L \tilde{f}^L,\ w_R \tilde{f}^R,\ w_I \tilde{f}^I) \tag{4.18}$$

并通过轻量 MLP 得到输出表示 $\phi(z)$。在模块级自测中，仓库实现提供一个均方误差主损失与可靠性方差正则（鼓励各模态可靠性不过度塌缩到单一模态）：

$$\mathcal{L} = \mathcal{L}_{\text{mse}} + \lambda_{\text{rel}} \operatorname{Var}(r_L, r_R, r_I) \tag{4.19}$$

4.8 与强化学习的联合优化（SAC）

本文采用 SAC 算法 [9] 进行策略学习。融合模块输出的特征作为策略网络与价值网络的输入，从而实现端到端训练。训练实现基于 Stable-Baselines3[10]，环境接口来自 Gymnasium[11]。

4.9 理论分析补充：鲁棒性与信息论（基于假设的推导）

为提升论文的理论完整性，本节给出与项目设计一致的若干推导与结论（在一定假设下成立）。需要强调的是：

- 当前仓库实现已经包含：可靠性估计器、注意力权重分配（带温度与偏置）、以及可靠性调制的逐模态归一化层。
- 本节中关于” 收敛性（李雅普诺夫意义）” 与”H_∞ 鲁棒性” 的讨论属于理论动机/可能的研究扩展，并不等价于对当前实现与训练流程的严格保证。相关控制理论背景可参考 [13-14]。

4.9.1　最坏情况鲁棒性直观分析

考虑极端退化：某一模态完全失效时，其可靠性应趋近于 0；若权重分配机制能够令对应权重趋近于 0，则融合输出将主要由剩余模态决定，从而避免将失效模态噪声注入策略输入。与固定权重 $\mathbf{w} = (1/3, 1/3, 1/3)$ 相比，该机制在最坏情形下具有更小的加权误差。

4.9.2　互信息视角的融合动机

从信息论角度，融合目标可理解为最大化融合特征 Z 与任务变量 Y 之间的互信息 $\mathcal{I}(Z;Y)$[15]。若做如下假设：

$$r_m \propto \mathcal{I}(Z_m;Y) \tag{4.20}$$

即” 可靠性越高的模态包含越多与任务相关的信息”，则令权重 w_m 随 r_m 单调增加（例如通过 softmax）可在一定条件下提升加权信息量的下界。一个直观推导如下：令 $I_m = \mathcal{I}(Z_m;Y)$，固定权重下有 $\frac{1}{3}\sum_m I_m$；而若取 $w_m \propto I_m$，则加权信息为 $\sum_m w_m I_m = \frac{\sum_m I_m^2}{\sum_k I_k}$。由于 x^2 为凸函数，可由 Jensen 不等式推出 $\frac{\sum_m I_m^2}{\sum_k I_k} \geq \frac{1}{3}\sum_m I_m$。

4.10　与 SB3 特征提取器的接口约束

为了兼容 Stable-Baselines3 的 MultiInputPolicy，特征提取器需满足：

- 输入为字典观测（包含 lidar/rgb/imu 键）；
- 输出为固定维度特征向量（默认 256 维）；
- 支持” 可靠性融合模式” 与” 基线拼接模式” 切换，以便消融对比。

第五章　实验设计与评估

5.1　实验目标

实验围绕以下三个问题展开：

- 有效性：可靠性感知融合相较固定权重与无可靠性基线是否带来性能收益；
- 鲁棒性：在传感器退化条件下，是否能降低碰撞等失效行为；
- 工程可用性：训练与推理开销是否可接受，是否具备可复现实验流程。

5.2　实验设置

5.2.1　算法与实现

本文采用 SAC[9] 作为强化学习算法，基于 Stable-Baselines3[10] 的 MultiInputPolicy。融合模块封装为自定义 BaseFeaturesExtractor，并支持以下可控开关：

- 可靠性融合开关（–no-reliability）；
- 可靠性调制归一化开关（–no-reliability-modulation）；
- 固定权重融合（fixed_weights）；
- 共享/非共享特征提取器（share_features_extractor）。

5.2.2　环境与退化注入

环境为三模态 UAV 仿真环境（LiDAR/RGB/IMU），支持显式退化注入：

1、 LiDAR：点云随机丢失与高斯噪声；

2、 RGB：模糊、噪声与随机遮挡；

3、 IMU：噪声、漂移与随机通道丢失。

同时支持 easy/medium/hard 三档任务难度，用于避免“所有方法成功率均接近 100%”导致的区分度不足。

5.2.3　可复现实验脚本

本文实验采用统一脚本：

- 主训练入口：train.py
- 套件对比入口：experiments/run_suite.py

- 基线脚本：experiments/baseline_fixed_weight.py、experiments/ablation_no_reliability.py

主要结果文件保存在 logs/experiments/*/suite_summary.csv。

5.3　评价指标

本文报告以下指标：

- 成功率（Success Rate）
- 碰撞率（Collision Rate）
- 超时率（Time-limit Rate）
- 平均步数（Avg Steps）
- 平均回报（Avg Reward）
- 平均推理时延（Inference ms Mean）
- 训练耗时（Training Seconds）

这些指标由统一评估函数自动统计，终止原因通过环境 info['termination_reason'] 区分成功/碰撞/越界/超时。

5.4　对比方法

本文比较四种方法：

1、 **ours_dynamic**：可靠性估计 + 动态权重 + 可靠性调制归一化（本文方法）；
2、 **no_reliability**：禁用可靠性融合，采用直接拼接基线；
3、 **fixed_equal**：可靠性分支保留，但融合权重固定为 $(1/3, 1/3, 1/3)$；
4、 **no_norm_modulation**：关闭可靠性调制归一化，仅保留常规归一化。

5.5　结果与分析（当前可复现结果）

5.5.1　中等难度结果（single seed，degradation=0.5）

表1对应 suite_iter_v1（seed=42）。

5.5.2　困难难度结果（single seed，degradation=0.5）

表2对应 suite_iter_hard_v1（seed=42）。

表 1　中等难度结果（degradation=0.5，seed=42）

方法	训练 (s)	成功率 (%)	碰撞率 (%)	超时率 (%)	平均步数	平均回报	推理 (ms)
ours_dynamic	30.15	100.0	0.0	0.0	137.00	920.65	3.34
no_reliability	10.73	100.0	0.0	0.0	73.00	801.13	0.95
fixed_equal	30.16	100.0	0.0	0.0	91.00	838.43	3.31
no_norm_modulation	30.32	100.0	0.0	0.0	151.00	943.92	3.36

表 2　困难难度结果（degradation=0.5，seed=42）

方法	训练 (s)	成功率 (%)	碰撞率 (%)	超时率 (%)	平均步数	平均回报	推理 (ms)
ours_dynamic	30.73	0.0	5.0	95.0	196.15	585.90	3.42
no_reliability	10.43	0.0	30.0	70.0	177.80	466.26	0.89
fixed_equal	31.25	0.0	15.0	85.0	187.55	608.29	3.26
no_norm_modulation	30.68	0.0	5.0	95.0	195.65	607.20	3.52

5.5.3　困难难度三随机种子汇总（timesteps=1000）

进一步使用 seeds=42,43,44 重复实验，并对每个方法做均值 ± 标准差汇总（来自 suite_iter_hard_ms1）。

表 3　困难难度三随机种子汇总（degradation=0.5）

方法	训练耗时 (s)	碰撞率	超时率	平均回报
ours_dynamic	39.98 ± 3.03	0.100 ± 0.108	0.900 ± 0.108	592.43 ± 71.22
no_reliability	15.72 ± 0.94	0.233 ± 0.062	0.767 ± 0.062	554.50 ± 71.32
fixed_equal	40.59 ± 5.89	0.117 ± 0.047	0.883 ± 0.047	620.37 ± 12.93
no_norm_modulation	41.61 ± 5.32	0.117 ± 0.094	0.883 ± 0.094	597.39 ± 81.74

5.5.4　结果讨论

- 在中等难度下，各方法成功率均为 100%，说明该设置区分度有限，但本文方法相对无可靠性基线有更高回报。
- 在困难难度下（max_steps=200），各方法成功率均为 0，主要失败类型是“超时未到达目标”，说明当前训练步数与回合时间预算共同限制了成功率上限。
- 即使在该苛刻设置下，多随机种子统计显示无可靠性基线碰撞率最高（0.233 ± 0.062），而本文方法为 0.100 ± 0.108，说明显式可靠性感知仍有助于降低高风险碰

撞失效。

- 可靠性分支方法推理耗时约 3.3ms，仍满足实时性目标（<30ms）；无可靠性基线更快（约 0.9ms），但鲁棒性较弱。
- 归一化调制消融（no_norm_modulation）与本文方法在困难场景碰撞率接近，表明当前调制机制仍有进一步调参空间。

5.6　当前局限与后续迭代

- 当前结果仍以单随机种子为主，统计显著性不足；
- 训练步数以 1k 级别为主，尚未覆盖 10k~100k 长时训练稳定性；
- 与外部代表性融合基线（非本仓库实现）对比仍待补齐。

下一步将重点开展多随机种子实验（至少 3 个种子）与更长训练步数的系统评测，并报告均值与方差。

第六章　工程实现与复现说明

6.1　代码结构

项目核心代码位于仓库根目录，关键路径如下：

- envs/uav_multimodal_env.py：多模态环境、退化注入、难度分级
- networks/reliability_estimators/：LiDAR/RGB/IMU 可靠性估计器
- networks/reliability_predictor.py：可靠性预测网络
- networks/dynamic_weighting_layer.py：动态权重分配
- networks/adaptive_normalization.py：可靠性调制归一化
- networks/reliability_aware_fusion.py：端到端融合模块
- networks/uav_multimodal_extractor.py：SB3 特征提取器
- train.py：统一训练入口
- utils/experiment_pipeline.py：训练/评估通用流水线
- experiments/run_suite.py：对比与消融套件

6.2　关键接口与张量形状

- LiDAR 输入：$(B, 1000, 3)$
- RGB 输入：环境输出 $(B, 128, 128, 3)$（NHWC），提取器内转换为 $(B, 3, 128, 128)$（NCHW）
- IMU 输入：环境输出 $(B, 6)$，提取器内扩展为 $(B, 16, 6)$ 用于时序一致性建模
- 特征提取器输出：$(B, 256)$

6.3　模型规模与开销

基于当前实现统计，核心参数规模如下：

- **ReliabilityPredictor**：151,769 参数（约 151.8K）
- **ReliabilityAwareFusionModule**：719,398 参数（约 719.4K）
- **SAC** 策略总参数（共享特征提取器）：2,350,500（约 2.35M）
- **SAC** 策略总参数（非共享）：3,193,200（约 3.19M）

6.4 训练性能优化实现

针对早期“训练时间明显长于预期”的问题，工程上完成了以下优化：

1、 环境侧优化：LiDAR 障碍重采样由逐点循环改为向量化；RGB 渲染网格改为缓存复用。

2、 网络侧优化：IMU 一致性分支改为共享时序 CNN 编码，移除重复分支与高开销时序路径。

3、 训练侧优化：默认开启 share_features_extractor=True，非 debug 下使用单次 learn() 减少循环调度开销。

优化后在本地 CPU 上可稳定完成 1000 步训练，典型耗时约 32 秒（GAP 编码器、可靠性模式、共享特征提取器）。

6.5 运行方式

6.5.1 训练入口

train.py 当前支持以下关键参数：

- 训练步数：–timesteps
- 可靠性开关：–no-reliability
- 归一化调制开关：–no-reliability-modulation
- 退化强度：–degradation-level
- 难度分级：–difficulty easy|medium|hard
- 共享提取器开关：–no-share-features-extractor
- IMU 历史长度：–imu-history-len

6.5.2 实验套件

experiments/run_suite.py 可一键执行“本文方法 + 基线 + 消融”并输出：

- suite_results.json：完整结构化结果
- suite_summary.csv：可直接制表与画图的扁平结果

6.6 测试与复现状态

- 集成与编码器测试通过（24 项）；
- 训练与评估脚本可在本地 CPU 复现并输出结构化结果；
- 退化注入与难度分级已并入统一环境接口。

6.7 未完成事项

- 10k~100k 步长时训练的系统统计仍在进行中；
- 多随机种子（≥ 3）的均值/方差表尚待补齐；
- 面向真实传感器数据与真实机平台的迁移验证尚未开展。

总结

本文围绕复杂环境下 UAV 多模态导航的鲁棒感知问题，提出并实现了多维度可靠性感知的自适应融合框架（Idea1）。该方法通过显式可靠性估计（LiDAR SNR、RGB 质量、IMU 一致性）、注意力驱动的动态权重分配以及可靠性调制归一化，在特征层实现了可解释、可调试的融合路径，并与 Stable-Baselines3 的 SAC 训练流程完成端到端集成。

在工程实现方面，本文完成了所有核心模块（可靠性估计器、可靠性预测网络、动态权重分配层、可靠性调制归一化层、端到端融合模块）以及支持退化注入与难度分级的 UAV 多模态仿真环境，并通过集成测试验证了可运行性。当前实现中，可靠性预测网络参数量约 151.8K，融合模块约 719.4K；在共享特征提取器配置下，SAC 策略总参数约 2.35M。针对训练耗时问题，本文进一步完成了环境向量化与训练流程优化，使本地 CPU 下 1000 步训练可稳定在约 32 秒完成。

实验层面，本文已完成可复现对比套件，并在退化场景（degradation=0.5）下获得初步结果：中等难度下各方法均可达到较高成功率；困难难度下，无可靠性基线碰撞率上升至 30%，而本文方法保持在 5%，显示可靠性感知机制对鲁棒性具有积极作用。

后续工作将重点补齐：(1) 多随机种子统计（均值/方差与显著性检验）；(2) GPU 环境下 10k~100k 步长时训练稳定性验证；(3) 更多外部代表性融合基线对比；(4) 面向真实数据与真实机平台的迁移与验证；(5) 进一步优化可靠性调制归一化的参数化形式与训练策略。

参 考 文 献

[1] T. Baltrusaitis, C. Ahuja, L.-P. Morency. Multimodal machine learning: A survey and taxonomy[EB/OL]. 2017. https://arxiv.org/abs/1705.09406.

[2] Q. Zhang, Y. Wei, Z. Han, et al. Multimodal fusion on low-quality data: A comprehensive survey[EB/OL]. 2024. https://arxiv.org/abs/2404.18947.

[3] Y. Gal, Z. Ghahramani. Dropout as a bayesian approximation: Representing model uncertainty in deep learning[C/OL]//Proceedings of the 33rd International Conference on Machine Learning (ICML). 2016: 1050-1059. http://proceedings.mlr.press/v48/gal16.html.

[4] A. Kendall, Y. Gal. What uncertainties do we need in bayesian deep learning for computer vision?[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/2650d6089a6d640c5e85b2b88265dc2b-Paper.pdf.

[5] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention is all you need[C/OL]//Advances in Neural Information Processing Systems (NeurIPS). 2017. https://arxiv.org/abs/1706.03762.

[6] Z. Liu, H. Tang, A. Amini, et al. Bevfusion: Multi-task multi-sensor fusion with unified bird's-eye view representation[EB/OL]. 2024. https://arxiv.org/abs/2205.13542.

[7] C. Liao, K. Lei, X. Zheng, et al. Benchmarking multi-modal semantic segmentation under sensor failures: Missing and noisy modality robustness[EB/OL]. 2025. https://arxiv.org/abs/2503.18445.

[8] K. Park, Y. Kim, D. Kim, et al. Resilient sensor fusion under adverse sensor failures via multi-modal expert fusion[EB/OL]. 2025. https://arxiv.org/abs/2503.19776.

[9] T. Haarnoja, A. Zhou, P. Abbeel, et al. Soft actor-critic algorithms and applications[J/OL]. arXiv preprint arXiv:1812.05905, 2018. https://arxiv.org/abs/1812.05905.

[10] A. Raffin, A. Hill, A. Gleave, et al. Stable-baselines3: Reliable reinforcement learning implementations[EB/OL]. 2021. https://github.com/DLR-RM/stable-baselines3.

[11] Farama Foundation. Gymnasium: A standard api for reinforcement learning environments [EB/OL]. 2023. https://gymnasium.farama.org/.

[12] A. Paszke, S. Gross, F. Massa, et al. Pytorch: An imperative style, high-performance deep learning library[C/OL]//Advances in Neural Information Processing Systems (NeurIPS). 2019. https://pytorch.org/.

[13] H. K. Khalil. Nonlinear systems[M]. 3rd ed. [S.l.]: Prentice Hall, 2002.

[14] K. Zhou, J. C. Doyle, K. Glover. Robust and optimal control[M]. [S.l.]: Prentice Hall, 1996.

[15] T. M. Cover, J. A. Thomas. Elements of information theory[M]. 2nd ed. [S.l.]: Wiley, 2006.

附录 A　常见问题

1、 本模板如何使用?

- 按照第 2 章的要求，先下载和安装相应的软件，推荐使用 TEXLive2012 或更新的版本;
- 下载 cls 文件;
- 使用 tex 的编辑器或其他编辑器，编写论文，注意保存为 UTF-8 编码;
- xelatex 编译。

注意：TEXLive2012 的 ISO 镜像在未来花园 BT 站上有相应的种子可下载，亦可从 TUG 的官方网站上下载。

2、 Windows 下的 msmake.bat 如何使用?

- 使用 Windows 的 CMD 命令行，进入到 msmake.bat 所在目录;
- 键入 msmake 后会显示相应的帮助文件;
- 按照所显示的相关信息再键入相应命令即可。

注意：由于此批处理文件为编者自行编写，学识有限，代码有许多不如人意之处，如对此批处理文件有问题可直接邮件联系我 (mrpeng000@gmail.com) 即可。

3、 使用 TexLive 如何更新? TUG 官方推荐 TEXLive 通过镜像站进行更新，具体步骤为:

- 在“开始”目录下的 TeXLive2012 文件夹下，找到有 TeX Live Manage 程序;
- 在菜单“tlmgr”下选择“载入其他仓库”, 选择最近的仓库即可（如果是北航校内用户并能够访问到北航开源镜像站的话,可以在仓库地址中输入 http://mirror.buaa.edu.
- 按照目录选择更新。

附录 B　联系我们

致谢

作者简介

xxxx 年 xx 月 xx 日出生于 xx 省 xx 县。

xxxx 年 9 月考入 xx 大学 xx 系 xx 专业，xxxx 年 7 月本科毕业并获得 xx 学士学位。

xxxx 年 9 月免试进入 xx 大学 xx 系攻读 xx 学位至今。